


LLM 評測知識庫： 系統化評估與安全防護指南

方法論、基準測試與紅隊演練



涵蓋 35+ 篇核心學術論文與實務架構分析



建立可信賴 AI 的三大核心支柱

本知識庫整合學術界與產業界最佳實務，提供從理論到防禦的完整路徑。



評估指標體系：定義 LLM 效能的四個維度



準確率 (Accuracy)

模型回答的精確程度與正確率。衡量模型是否能針對事實性問題提供標準答案。



相關性 (Relevance)

輸出內容與使用者 Prompt 的關聯強度。確保回答不偏題，直接回應使用者意圖。



真實性 (Truthfulness)

內容是否符合客觀事實。重點在於降低**幻覺 (Hallucination)** 與錯誤資訊的生成。




一致性 (Consistency)

在相似輸入下維持輸出邏輯與風格的穩定度。確保多次詢問不出現矛盾觀點。

Responsible AI 標準與倫理合規

除了效能指標，模型必須符合倫理規範與法規要求，確保技術發展與社會價值相容。




核心評測研究：從 HELM 到 LLM-as-a-Judge

全面性評估 (HELM)

Liang et al., 2023


HELM (Holistic Evaluation of Language Models) 建立了多維度的評估標準，強調不應僅依賴單一指標，需涵蓋準確、毒性、效率等面向。




自動化評審 (LLM-as-a-Judge)

Zheng et al., 2023 (MT-Bench)

利用強大模型（如 GPT-4）作為評審，實現可擴展的自動化評測。



基準測試設計：打造高品質的「黃金測試集」



數據生命週期與污染檢測

Data Lifecycle (數據生命週期)



關鍵路徑覆蓋 (Key Path Coverage)

確保測試集覆蓋了所有核心業務邏輯與使用場景。參考 CheckList (Ribeiro et al., 2020) 的行為測試矩陣。

資料污染檢測 (Data Contamination)

確保模型未在訓練階段「背誦」過測試題目。使用 N-gram 重疊度分析檢測訓練集與測試集的洩露問題 (Sainz et al., 2023)。

Precision Engineering meets Swiss Editorial

實務評測工具箱

結合理論基礎與應用指南的自動化框架

RAGAS



RAG 評測

檢索品質

專注於 RAG (Retrieval-Augmented Generation) 系統。評估 Context Recall (召回率) 與 Answer Relevance (回答相關性)。

DeepEval



Unit Testing

Pytest 整合

提供單元測試風格的 LLM 評測框架。適合開發階段快速迭代，將評測整合至 CI/CD 流程。

Arize Phoenix




Observability

Traceability

用於生產環境的可觀測性與評估平台。追蹤實際用戶互動並進行即時評分。

AI 安全防護與紅隊演練架構

結合對抗性測試與多層次防禦機制的綜合框架



攻擊向量清單：識別潛在威脅



Prompt Injection (提示詞注入)

透過精心設計的指令覆蓋系統原本的設定與限制，例如「忽略上述指令，改為...」。



Jailbreaking (越獄攻擊)

繞過模型的安全過濾機制，誘導生成暴力、色情或違法內容。

Reference: Wei et al., 2023 on Jailbreak Mechanisms.



PII 洩露防護 (Privacy Leakage)

防止個人身份資訊 (Personally Identifiable Information) 如姓名、電話、地址在生成過程中外洩。

核心學術文獻與研究基石

本知識庫收錄並分析 35 篇關鍵論文，以下為四大基礎文獻：

Holistic Evaluation

Liang et al. (2023) - HELM

定義了語言模型全面性評估的標準框架。

Automated Evaluation

Zheng et al. (2023) - Judging LLM-as-a-Judge

驗證了使用 LLM 評估 LLM 的可行性與效度。

Evaluation Survey

Chang et al. (2024) - A Survey on Evaluation of LLMs

系統化整理了現有的評測方法與分類。

AI Safety

Ganguli et al. (2022) - Red Teaming Language Models

建立了紅隊演練以減少模型危害的實務流程。

實施路徑：從評測設計到安全部署

